

최종 수행보고서

Size Aware Virtual Try-On Using Diffusion Model(SA-VTON)



1. 연구동기

플랫폼의 발전과 함께 온라인으로 의류를 구매하는 것이 일상화되었다. 하지만 다른 상품과는 다르게 의류는 입을 봐야 확실하게 자신이 원하던 옷인지 알 수 있기 때문에 오프라인 구매를 선호하는 층이 공고히 존재하고 온라인 구매에서도 이로 인한 단점들이 나오고 있다. 현재는 많은 기업이 자유로운 반품 시스템을 제공하고 있지만, 이는 판매자와 구매자 모두에게 손해이다. 구매자는 귀찮은 반품 과정을 거치며 시간적인 손실과 추가 비용을 감수해야 할 수도 있고 판매자 역시 재고 관리나 반품 처리 비용에서 부담이 있다. 이에 기업에서는 의류에 대해 최대한 자세하게 정보를 제공하는 방식으로 이를 해결하려 하고 있지만 근본적인 한계가 존재한다. 이러한 상황에서 온라인으로 옷을 입을 수 있는 서비스가 있다면 좋은 해결책이 될 것이다.

가상으로 옷을 입히는 작업은 인공지능 붐이 오기 전부터 연구되어왔다. 그 당시에는 컴퓨터 그래픽스의 방법론을 통해 이 작업을 수행하고자 했는데 특수 카메라나 센서 등 고가의 하드웨어 그리고 옷과 모델에 대한 3d 정보가 필요하다는 것 등에서 실생활에서 쓰이기에는 명확한 한계가 존재했다. 하지만 딥러닝과 CNN이 등장하면서 2차원의 옷과 모델의 정보만을 가지고 그럴싸하게 옷을 입은 이미지를 생성하려는 시도들이 나타나기 시작했다. 이 작업은 결국 생성형 인공지능이라는 분야의 발전과 결을 같이 하게 되는데 최근 생성형 인공지능 분야는 폭발적인 성장을 하고 있다. OpenAi의 chat gpt, 수많은 이미지 및 동영상 생성 모델들이 바로 생성형 인공지능의 산물이다. 가상 피팅 역시 전과 달리 실생활에서 쓰일 수 있다는 가능성을 보여주며 많은 연구가 진행되고 있다.

가상 피팅 기술이 상용화되기 위해서는 해당 옷의 사이즈나 핏을 정확히 반영해주는 것이

필수적이다. 사이즈를 무시한 채 그럴듯하게 입혀주는 것은 옷의 디자인이나 색감이 본인과 잘 어울리는지 정도만 확인할 수 있을 뿐이고 위와 같은 반품 문제를 근본적으로 해결할 수 없다. Diffusion이 등장하기 전까지는 그럴듯하게 입혀주는 것조차 깔끔하게 이뤄지지 않아 사이즈를 비롯한 이후의 문제들은 그렇게 중요한 주제가 아니었다.

Diffusion은 가장 최신의 이미지 생성형 모델로 GAN과 같은 이전의 모델과 비교가 되지 않을 정도로 압도적인 성능을 보이고 있다. 가상 피팅 분야 역시 이 diffusion 모델을 차용하여 이전과 궤를 달리하는 성과를 내고 있다. 하지만 diffusion에 특정한 조건을 주어 결과에 영향을 주는 컨디셔닝에 관한 연구는 아직 미흡한 상황이다. 현재 상용화되고 있는 여러 이미지 생성 서비스에서도 이 부분은 가장 큰 단점으로 지적된다. 주어진 주제에 대해 그럴듯하게 멋진 이미지를 생성하는 것은 잘하지만, 그 이미지에서 일부는 유지한 채 마음에 들지 않는 부분만 수정을 하는 것은 매우 힘들다.

본 연구에서는 앞서 언급한 사이즈를 반영하는 가상 피팅을 diffusion 모델에 조건을 주는 방식으로 해결하고자 한다. 만약 사이즈를 다르게 해서 어떤 결과가 나오는지 옷, 모델 데이터가 충분히 있다면 굳이 모델을 건드리며 조건을 주는 부분을 추가할 필요 없이 훈련만 대규모로 진행하여 위의 목적을 달성할 수도 있을 것이다. 하지만 일반적인 옷, 모델 데이터와 달리 자신에게 맞지 않는 옷, 모델 데이터는 얻기가 매우 힘들다. 이처럼 데이터가 부족한 상황에서 인간의 사전 지식을 활용하여 문제를 해결하는 경우가 많다. 본 연구에서는 기존의 데이터만을 사용하되 인위적인 조건을 추가하여 원하는 결과를 얻어볼 것이며 이는 다른 diffusion 모델의 컨디셔닝에 관한 연구에도 의미가 있는 연구가 될 것이다.

2. 연구목표

우리의 목표는 사이즈를 통해 조건화가 가능한 가상 피팅 모델을 만드는 것이다. 우선 모델의 입력을 변형했을 때 결과가 어떻게 변하는지를 확인해볼 것이며 추가적인 정보를 주어 훈련도 해볼 것이다. 본 연구에서는 비율을 통해 옷의 크기를 인위적으로 늘리고 줄이는 기존의 방식을 사용하여 입력을 다르게 주었고 그 결과를 확인해보았다. 또한 세그멘테이션 맵을 입력에 추가하여 결과에 영향을 줄 수 있도록 훈련했는데 단순히 추가를 한 것만으로도 의미있는 결과를 확인할 수 있었고 세그멘테이션 맵에 변형을 주었을 때의 결과의 변화도 관찰해보았다.

3. 연구내용

3.1. VTON 소개

3.1.1. VTON의 발전과 분류

가상 착용(Virtual Try-On, VTON)은 디지털 환경에서 사용자에게 옷의 착용감을 시각적으로 제공하기 위해 개발된 기술로, 2001년 Cordier et al.에 의해 처음 제안되었다. 초기 연구는 신체 데이터베이스와 의류 모델을 기반으로 개별 사용자 맞춤형 신체와 의류 시뮬레이션을 구현하는 방식이다. 이후 VTON 기술은 기술적 접근 방식에 따라 크게 물리 기반 시뮬레이션, 실제 데이터 획득, 그리고 이미지 생성 기반 방법으로 나뉘며 발전해왔다. (Song et al., 2024)

1. 물리 기반 시뮬레이션은 인체 모델과 의류의 움직임을 물리적으로 계산하여 사실적인 시뮬레이션을 제공하는 기술이다. Tang et al.(2016, 2018a, 2018b)의 연구는 의류와 신체 간의 상호작용을 정밀하게 표현하기 위해 물리 법칙에 기반한 접근을 개발했다. 이러한 기술은 사실적인 표현을 가능하게 해 상업적 도구로 채택되기도 했지만, 계산 복잡성으로 인해 적용 범위가 제한적일 수 있다.

2. 실제 데이터 획득은 조정 가능한 로봇을 통해 실제 의류의 외형을 캡처하고 이를 디지털화하여 사용자가 착용 상태를 확인할 수 있도록 하는 방법이다. 이 접근법은 높은 사실성을 보장하지만, 대규모 데이터 수집에 있어 시간과 비용 측면에서 제약이 크다는 한계를 가진다.

3. 이미지 생성 기반 방법은 최근 들어 주목받고 있는 방식으로, 인체와 의류 이미지를 활용하여 가상 착용 결과를 시각적으로 생성하는 기술이다. 이 방식은 물리적 데이터가 불필요하다는 점에서 효율적이고 비용 효율적인 접근으로 평가받고 있지만, 생성된 이미지의 왜곡이나 자연스러움 부족 등으로 인해 여전히 실용화 단계에서는 과제가 남아 있다.

본 연구에서는 특히 3.이미지 생성 기반 가상 착용 기술에 중점을 두어, 현재의 한계를 극복하기 위한 방안을 제시하고자 한다.

3.1.2. 이미지 생성기반 VTON 연구 동향

최근 VTON 연구는 이미지 생성 기반 방법에 크게 주목하고 있다. 물리적 데이터를 필요로 하지 않아 효율성과 비용 측면에서 장점을 가지는 이 접근법은 특히 딥러닝 기술의 발전과 함께 빠르게 성장하고 있다. 표에 나타난 바와 같이, 2017년부터 현재까지 이미지 생성 기반 VTON 연구는 GAN(Generative Adversarial Network)과 Diffusion 모델을 중심으로 꾸준히 발전해왔다.

초기 연구들은 GAN 구조를 활용하여 인체와 의류 이미지를 결합해 가상 착용 이미지를 생성하는 데 집중했다. 예를 들어, 2017년에 발표된 CAGAN은 Cycle-GAN 구조를 기반으로 하여 VTON 연구의 첫걸음을 내디뎠다. 이후 VITON(2018), CP-VTON(2018) 등의 연구는 모

텔 구조의 개선을 통해 생성된 이미지의 품질을 높이는 데 기여했다. 2019년에는 UVTON과 O-VITON(2020) 등 다중 의류 착용에 초점을 맞춘 연구들이 등장하며, 사용자 맞춤형 가상 착용 서비스의 가능성을 확장했다.

최근 연구는 더 높은 해상도와 자연스러운 의류 디테일을 생성하는 데 초점을 맞추고 있다. 예를 들어, VITON-HD(2021)와 HR-VTON(2022)은 고해상도 이미지를 생성하여 사실감을 한층 높였으며, Diffusion 모델을 활용한 2023년 이후의 연구는 자연스러움과 정확성에서 획기적인 발전을 보여주고 있다.

Year	Research Name	Journal	Characteristic
2017	CAGAN	ICCVW	Cycle-GAN Structure
2018	VITON	CVPR	Others
2018	SwapNet	ECCV	Others
2018	CP-VTON	ECCV	Others
2019	LA-VTON	ICCVW	Others
2019	ClothFlow	ICCV	Others
2019	UVTON	ICCVW	Multi-Garment Try-On
2019	VTNFP	ICCV	Others
2019	RCW	ICCVW	Others
2019	PVT	ICCVW	Others
2020	ACGPN	CVPR	Others
2020	WUTON	ECCV	Teacher-Student Structure
2020	SP-VITON	MTA	Others
2020	O-VITON	CVPR	Multi-Garment Try-On
2020	CP-VTON+	CVPR	Others
2021	TryOnGAN	ACMTG	Implicit Transformation
2021	VITON-HD	CVPR	High Resolution
2021	LM-VTON	AAAI	Others
2021	DCTON	CVPR	Cycle-GAN Structure
2021	PFAFN	CVPR	Teacher-Student Structure
2021	OVNet	CVPR	Multi-Garment Try-On
2021	ZFlow	ICCV	Others
2021	DiOr	ICCV	Multi-Garment Try-On
2021	CIT	CVPR	Others
2022	DGP	CVPR	Implicit Transformation
2022	SDAFN	ECCV	Others
2022	C-VTON	WACV	Others
2022	SF-VTON	CVPR	Teacher-Student Structure
2022	HR-VTON	ECCV	High Resolution
2022	3D-GCL	NeurIPS	Others
2023	TryOnDiffusion	CVPR	Implicit Transformation
2023	KGI	ICCV	High Resolution
2023	SAL-VTON	CVPR	Teacher-Student Structure
2023	GP-VTON	CVPR	Others
2023	COTTON	ICCV	High Resolution
2023	DCI-VTON	ACM MM	Diffusion Tuning
2023	LaDI-VTON	ACM MM	Diffusion Tuning
2024	TPD	AAAI	Diffusion Tuning
2024	Stable VITON	CVPR	Diffusion Tuning
2024	CAT-DM	CVPR	Diffusion Tuning

Figure 1. VTON 연구 흐름

3.1.3. GAN과 Diffusion 기반 VTON 연구의 주요 특징과 발전

VTON 연구는 이미지 생성 방식에서 주로 GAN과 Diffusion 모델 두 가지 접근으로 나뉜다. 이 두 방법은 가상 착용 이미지를 생성하는 데 있어 각각의 장점과 과제를 가지고 있다.

GAN 기반 VTON 연구

GAN 기반 Virtual Try-On (VTON) 연구는 생성적 적대 신경망(GAN)의 특성을 활용해 사실적인 이미지를 생성하는 데 초점을 맞추었다. GAN은 생성자(Generator)와 판별자(Discriminator)가 경쟁적으로 학습하며, 높은 학습 효율성과 빠른 생성 속도를 가진다는 장점이 있다. 초기 연구에서는 이러한 장점을 활용하여 비교적 단순한 구조에서도 고품질의 이미지를 생성하는 데 성공했다. 대표적인 연구로는 CycleGAN 구조를 확장한 Conditional Analogous GAN(CAGAN)이 있다. CAGAN은 CycleGAN의 방식을 기반으로 사용자 이미지와 의류 간의 일관성 있는 변환을 수행하며, 신체와 배경을 자연스럽게 유지하는 데 중점을 두었다(Zhu et al., 2017).

이후 연구들은 의류와 신체 이미지 간의 정렬 및 변형을 더욱 정교하게 처리하기 위해 다양한 방법을 도입했다. 예를 들어, DCTON(2021)은 Cloth Transfer를 위해 인코더-디코더 기반 구조를 활용하여 의류의 변형과 정렬 품질을 크게 개선했다.(Ge et al., 2021) 또 다른 연구인 PFAFN(2021)은 Teacher-Student 구조를 도입해 학습 안정성을 높이고 정렬 성능을 강화했다. 이는 고해상도 이미지를 효과적으로 생성하는 데 기여했다(Ge et al., 2021).

SF-VTON(2022)은 정교한 의류 디테일 표현을 목표로 삼았다. 이 연구는 신체-의류 간의 상호작용을 세밀히 모델링하며 사용자 맞춤형 착용감을 구현하는 데 주력했다(Jiang et al., 2022). 그러나 GAN 기반 모델은 여전히 이미지 왜곡 및 학습 불안정성과 같은 한계를 가지며, 의류의 자연스러운 디테일 표현에 한계가 있다는 점이 지적되고 있다. 이러한 문제는 여전히 VTON 연구에서 해결해야 할 주요 과제로 남아 있다.

Diffusion 모델 기반 VTON 연구

Diffusion 모델은 최근 VTON 연구에서 급부상한 기법으로, 노이즈가 섞인 이미지에서 점진적으로 복원하며 고해상도의 사실적인 이미지를 생성한다. Diffusion 기반 VTON 연구는 GAN에 비해 안정적인 학습과 더 높은 해상도의 이미지를 생성할 수 있다는 장점으로 주목받고 있다.

표에 나타난 DCI-VTON(2023), LaDI-VTON(2023), Stable VITON(2024), CAT-DM(2024) 등은 Diffusion Tuning 기법을 도입하여 생성된 이미지의 품질을 크게 개선했다. 특히 이들 연구는 의류와 신체 간의 복잡한 상호작용을 효과적으로 모델링하며, 사용자가 다양한 조건에서 고품질의 가상 착용 이미지를 얻을 수 있도록 했다.

GAN과 Diffusion 기반 방법의 발전은 VTON 기술의 상용화를 앞당기는 데 중요한 역할을 하고 있다. 향후 연구는 두 접근법의 장점을 결합하거나 새로운 모델 구조를 제안함으로써, 보다 현실적이고 사용자 친화적인 가상 착용 서비스를 개발하는 방향으로 나아갈 것이다.

3.1.4. 대표적인 VTON 모델

이미지 기반 가상 착용 기술의 발전은 GAN 및 Diffusion 기반 모델의 도입을 통해 가상 착용 이미지를 더욱 사실적이고 정밀하게 생성하는 방향으로 진화해왔다. 이 중 CP-VTON, ACGPN, LaDI-VTON은 각각의 독창적인 접근 방식으로 VTON 기술의 주요 과제를 해결하며 큰 기여를 했다. 아래는 각 모델의 기술적 기법과 성과이다.

CP-VTON(Wang et al., 2018)은 의류의 고유한 특징(텍스처, 로고, 자수)을 보존하며 사용자 신체에 자연스럽게 맞는 가상 착용 이미지를 생성하는 데 중점을 둔 모델이다. CP-VTON은 기존 수작업 기반의 형상 매칭 방식의 한계를 극복하기 위해, Geometric Matching Module (GMM)을 도입하여 학습 가능한 Thin-Plate Spline (TPS) 변환을 통해 의류와 신체를 정렬한다. 이 기법은 대규모 기하학적 변형을 다룰 수 있도록 설계되었으며, 의류 변형 과정의 자동화를 가능하게 했다. 또한, CP-VTON은 Try-On Module에서 변형된 의류 이미지를 신체 이미지와 결합하여 경계 부위의 아티팩트를 최소화하고 자연스러운 최종 이미지를 생성한다. 이러한 기술적 혁신은 기존 VITON(Han et al., 2018) 모델 대비 정렬 정확도와 이미지 품질에서 큰 향상을 이루며, 상업적 활용 가능성을 대폭 높였다.

ACGPN(Yang et al., 2020)은 복잡한 포즈와 신체-의류 간 상호작용 문제를 해결하고, 보다 사실적인 가상 착용 이미지를 생성하기 위해 제안되었다. ACGPN은 Semantic Layout Generation Module (SGM)을 활용해, 의미적 레이아웃을 생성하고 신체와 의류 간의 상호작용을 정밀하게 처리하며, 복잡한 포즈에서도 신체 비대상 영역을 효과적으로 보존한다. 또한, Clothes Warping Module (CWM)은 기존 TPS 기반 기법에 2차 차분 제약(Second-Order Difference Constraint)을 도입하여 복잡한 텍스처와 색상을 가진 의류에서도 안정적인 자연스러운 변형을 달성했다. 마지막으로, Content Fusion Module (CFM)은 의류와 신체 이미지를 융합하는 과정에서 생성이 필요한 부분과 보존이 필요한 부분을 구분하여 보다 세밀한 결과를 생성한다. ACGPN은 기존 모델들이 간과했던 신체 비대상 영역과 의류 디테일을 보존하는 데 성공하며, 어려운 착용 조건에서도 높은 품질의 이미지를 생성할 수 있음을 입증했다.

LaDI-VTON(Morelli et al., 2023)은 VTON 분야에서 Diffusion 모델을 최초로 도입하여, 가상 착용 이미지 생성에서 새로운 기준을 제시한 모델이다. LaDI-VTON은 Latent Diffusion Models (LDMs)의 강점을 활용하여, 고해상도 이미지를 생성하며, 의류의 질감과 텍스처를 정밀하게 보존한다. 이 모델은 특히 Textual Inversion Module을 통해 의류의 시각적 특징을 텍스트 임베딩(CLIP) 공간으로 매핑하고, 이를 기반으로 생성 과정을 조건화하여 더욱 디테일한 결과를 달성했다. 또한, Enhanced Mask-Aware Skip Connections (EMASC)를 사용해 인코딩 및 디코딩 단계에서 고주파 디테일을 보존하며, 얼굴, 손 등의 세부 표현에서 우수한 성능을 보였다. LaDI-VTON은 Diffusion 모델이 GAN 기반 모델보다 안정적이고 정밀한 결과를 제공할 수 있음을 입증하며, 가상 착용 기술의 새로운 가능성을 열었다.

CP-VTON, ACGPN, LaDI-VTON은 각각의 독창적인 기술적 접근으로 가상 착용 기술의 진화를 이끌며 사실적인 이미지 생성과 고유 의류 특징 보존에 크게 기여했다. 그러나 이들

모델은 공통적으로 착용자의 신체 사이즈를 명시적으로 반영하지 못하며, 다양한 체형과 사이즈에 대한 적응성을 제공하지 못하는 한계를 가진다. 이러한 제약은 실질적인 상업적 활용, 특히 사용자 맞춤형 가상 착용 서비스 제공에서 중요한 장벽으로 작용한다. 본 연구는 이 한계를 극복하기 위해 사이즈 정보를 인식하고 반영할 수 있는 Size-Aware VTON 모델을 개발하였으며, 이를 통해 기존 모델과의 성능 비교와 확장 가능성을 논의하고자 한다. Size-Aware VTON은 다양한 체형과 의류 사이즈를 동적으로 반영함으로써 사용자 경험을 한층 더 개인화하고, 가상 착용 기술의 상업적 적용 가능성을 한 단계 도약시킬 수 있을 것으로 기대된다.

3.2. Stable Diffusion

Stable Diffusion 은(Rombach et al., 2022) Latent Diffusion Models(LDMs)의 한 형태로, 이미지 생성을 위한 강력한 기법이다. 이 모델은 이미지의 고해상도와 디테일을 유지하면서도 효율적인 계산 자원을 활용해 GAN 기반 모델보다 더욱 안정적이고 높은 품질의 이미지를 생성할 수 있다. Stable Diffusion 은 Virtual Try-On 과 같은 의미론적 세부 사항이 중요한 이미지 생성 작업에서 널리 응용되고 있다.

Stable Diffusion 은 인코더 E 와 디코더 D 를 포함한 오토인코더 A , 텍스트-시간 조건부 U-Net 디노이징(denoising) 모델 ϵ_θ , 그리고 텍스트 Y 를 입력으로 받는 입력으로 받는 CLIP 텍스트 인코더 TE 로 구성되어 있다. 인코더 E 는 이미지 $I \in R^{(3 \times H \times W)}$ 를 $R^{4 \times h \times w}$ 의 낮은 차원의 잠재 공간(latent space)로 압축하며, 디코더 D 는 U-Net 을 거친 입력을 픽셀 공간으로 다시 디코딩한다. 여기서 $h = \frac{H}{8}$, $w = \frac{W}{8}$ 이다. Stable Diffusion 의 근간은 확산 과정(diffusion process)과 역확산 과정(reverse diffusion process)에 있다. 초기에는 랜덤한 잡음에서 시작하여 점진적으로 데이터 분포의 구조를 복원하는 역확산 과정을 통해 이미지를 생성한다. 이 과정은 고차원 이미지 데이터를 잠재 공간에서 저차원으로 표현하는 Variational Autoencoder(VAE)를 사용하여 구현된다.

확산 모델은 확률적으로 잡음을 단계적으로 추가하여 데이터의 구조를 소멸시키는 정방향 과정(forward process)과, 이와 반대로 데이터를 복원하는 역방향 과정(reverse process)으로 구성된다.

정방향 과정에서는 데이터 I_0 에 대해 시간 단계 t 마다 확률적인 잡음을 추가한다. 각 단계에서 I_t 는 다음과 같이 정의된다:

$$q(E(I_t) | E(I_{t-1})) = N(E(I_t); \sqrt{1 - \beta_t} I_{t-1}, \beta_t I)$$

여기서 β_t 는 각 단계에서 잡음의 크기를 조절하는 변수로, 단계가 진행될수록 잡음이 더해져 데이터의 구조가 소멸된다.

역방향 과정은 학습된 역확산 네트워크(denoising UNet)를 사용하여 잡음이 섞인 데이터 I_t 를 원래의 데이터 I_0 로 복원하는 과정을 수행한다. 이를 통해 모델은 초기의 랜덤한 잡음에서 시작하여 점진적으로 원본 데이터의 특성을 재현한다. 이때 손실 함수는 다음과 같은 LDM 손실 함수로 표현된다:

$$L_{LDM} = E_{E(I), Y, \epsilon \sim N(0, 1), t} \left[\left\| \epsilon - \epsilon_\theta(\gamma, \Psi) \right\|_2^2 \right]$$

여기서 γ 는 인코딩된 이미지 $E(I)$ 에 가우시안 노이즈 $\epsilon \sim N(0, 1)$ 이 확률적으로 더해진 것이다. ϵ_θ 는 네트워크가 학습을 통해 추정된 잡음이다. $\psi = [t; TE(Y)]$ 텍스트 인코더와 같은 모델의 추가 조건부 입력을 나타낸다.

우리는 모델 입력 이미지 I 에서 사용자 제공 의상 C 로 목표 의상을 교체하는 새로운 이미지 $\tilde{I}$ 를 생성하려고 한다. 이 작업은 사용자가 제공한 목표 의상 이미지에 따라 인간 이미지를 수정하는 특정 유형의 인페인팅(inpainting) 작업으로 볼 수 있다. 이러한 이유로, 우리는 Stable Diffusion의 인페인팅 파이프라인을 기반으로 사용하였다. 인페인팅 파이프라인은 인코딩된 마스크 이미지 $E(I_M)$, 크기 조정된 이진 인페인팅 마스크 $m \in 0, 1^{1 \times h \times w}$, 그리고 디노이징 네트워크 입력 $E(I_t)$ 를 채널 차원으로 연결한 값을 받는다. 여기서 x_m 은 인페인팅 마스크 $M \in 0, 1^{1 \times h \times w}$ 에 따라 마스크된 이미지 I 이며, 이진 인페인팅 마스크 m 은 인페인팅 마스크 M 의 잠재 공간 크기에 맞게 조정된 버전이다.

우리의 Virtual Try-On 모델은 전체 가상 착용 작업을 진행하기 위해 CLIP 텍스트 인코더는 사용하지 않았으며, 모델 입력 이미지 I 와 마스크된 이미지 M , 사람 포즈(pose) 맵 P , 사람 의상 세그멘테이션(segmentation) 맵 S , 모델이 신체의 형상에 맞게 워핑(warping)된 의상 C_W 를 사용하여 인페인팅 파이프라인을 조건화했다. 그리고 디노이징 네트워크 ϵ_θ 의 공간적 입력 $\gamma \in R^{9 \times h \times w}$ 에 크기가 조정된 포즈 맵 $p \in R^{18 \times h \times w}$ 과 세그멘테이션 맵 $s \in R^{1 \times h \times w}$, 인코딩된 워핑된 의상 $E(C_W) \in R^{4 \times h \times w}$ 를 연결하여 확장한다. 따라서 최종 공간 입력은 $\gamma = [E(I_t); m; E(I_M); p; s; E(C_W)] = R^{(9+18+1+4) \times h \times w}$ 이다. 최종적으로 우리 모델 디노이징 네트워크의 손실 함수는 다음과 같이 표현된다:

$$L = E_{E(I), Y, \epsilon \sim N(0, 1), t, E(I_M), M, p, s, E(C_W)} \left[\left\| \epsilon - \epsilon_\theta(\gamma) \right\|_2^2 \right]$$

기존 파이프라인의 디노이징 네트워크 ϵ_θ 의 입력 용량을 다시 처음부터 학습하지 않고도 확장하기 위해, 첫 번째 합성곱 계층의 커널 채널을 새로운 입력 채널 차원에 맞추기 위해 0으로 초기화된 가중치를 추가하여 확장한다. 이를 통해 기존 디노이징 네트워크에 포함된 지식을 유지하면서도 새롭게 확장된 입력을 처리할 수 있다.

3.3. Cloth-Warping

초기 가상 착용 연구에서는 Thin Plate Spline (TPS) 워핑이 의류를 신체에 맞추기 위한 주요 기법으로 사용되었다. TPS는 의류의 변형을 간단히 처리할 수 있는 방법이지만, 신체와 의류 간의 복잡한 관계를 충분히 반영하지 못해 왜곡이나 부자연스러운 결과를 초래하는 경우가 많았다. 이러한 한계를 해결하기 위해 Appearance Flow를 활용한 방법들이 도입되었다. (DCI-VTON) Gou et al., 2023, (PF-AFN) Ge et al., 2021, (ClothFlow) Han et al., 2019와 같은 연구는 의류와 신체의 정렬 문제를 개선하려는 시도를 보여주었으나, 여전히 신체 구조와 의류의 상호작용을 제대로 처리하지 못하여 복잡한 자세나 다양한 신체 조건에서 불일치가 발생하는 문제를 남겼다.

최근 연구들은 의류 변형의 정밀도를 높이고, 신체와 의류 간의 정렬 문제를 해결하기 위해 다양한 방식을 제안하였다. (HR-VTON) Lee et al., 2022은 Appearance Flow와 세분화(segmentation) 정보를 결합하여 불일치를 줄이고, 고해상도의 사실적인 결과를 생성하는 데 성공하였다. 그러나 텍스처와 디테일한 구조를 완벽히 유지하지는 못하였다. (PSGAN) Xie et al., 2021은 의류를 정규화된 패치 단위로 분리하여 공간 비중속적인 학습을 시도하였으며, 이를 통해 복잡한 의류 구조를 더 효과적으로 처리할 수 있는 가능성을 보였다. 그러나 의미론적 정보의 부족으로 의류의 전체적인 일관성을 유지하기 어려운 한계가 있었다. (DensePose VTON) Cui et al., 2023은 인체-의류 대응을 정밀히 학습하여 세밀한 변형을 가능하게 했지만, 높은 계산 비용으로 인해 실시간 응용에는 제약이 따랐다.

또한, 신체 비율을 반영한 워핑 방식을 제안한 연구도 있다. (Size Does Matter)는 의류의 크기와 신체 비율을 동시에 고려하는 접근 방식을 통해 사용자 맞춤형 결과를 생성하였다. 그러나 복잡한 자세나 다양한 의류 텍스처를 처리하는 과정에서 왜곡이 발생할 가능성이 남아 있었으며, 의미 분할의 정확성 문제 또한 해결되지 않은 상태로 남았다.

본 연구는 이러한 기존 연구들의 한계를 극복하기 위해 새로운 접근 방식을 제안한다. 제안된 방법은 복잡한 신체 자세나 다양한 체형에서도 자연스럽게 의류를 변형할 수 있는 방식을 통해 기존 방식에서 발생하던 왜곡과 부자연스러움을 줄인다. 또한, 사용자의 신체 비율과 체형을 반영하는 변형 과정을 설계하여 체형에 맞는 의류 변형을 구현하면서도 의류의 고유한 텍스처와 스타일을 손상시키지 않는다. 복잡한 의류 구조를 처리하기 위해 정교한 모델링 방식을 도입하여 의류의 형태적 완전성과 세부 텍스처를 보존하면서도 정확한 변형 결과를 제공한다. 이러한 접근은 기존 방식에서의 한계를 보완하며, 가상 착용 기술의 정밀도와 현실성을 동시에 향상시키는 데 기여한다.

3.4. Cloth Warping 개요

본 연구에서는 의류 랜드마크 예측, 세분화 네트워크, 랜드마크 기반 변형이라는 세 가지 구성 요소를 기반으로 Cloth Warping 방식을 제안한다. Cloth Warping은 신체의 랜드마크와 비율에 따라 의류를 정렬 및 변형하는 과정을 포함하며, 복잡한 신체 자세와 다양한 체형에서도 자연스러운 가상 착용 결과를 생성하는 데 핵심적인 역할을 한다.

이 과정은 기존 연구(Chen et al., 2023)의 Cloth Warping 아이디어를 기반으로 변형되었으며, 이를 본 연구에 적합하게 발전시켜 적용하였다. 이를 통해 다양한 조건에서도 강건한 성능을 보이는 가상 착용 기술을 실현하고자 한다.

3.4.1. 의류 랜드마크 예측기 (Clothing Landmark Predictor, CLP)

의류 랜드마크 예측은 Cloth Warping 과정에서 필수적인 단계로, 의류와 신체 간의 정밀한 변형과 자연스러운 정렬을 가능하게 하는 기초 데이터를 제공한다. 랜드마크는 의류의 기하학적 특징을 정의하며, 이는 신체 랜드마크와 상호 참조하여 의류를 정렬하고 변형할 수 있는 기준점을 형성한다. 본 연구에서는 랜드마크 예측기를 변형하고 이를 통해 의류의 주요 랜드마크를 정확히 추출하여, 다양한 체형과 자세에서도 강건하게 동작할 수 있도록 구현하였다.

의류 랜드마크의 개수와 위치는 의류의 유형에 따라 다르게 설정되며, 상의의 경우 목, 어깨, 팔꿈치, 손목, 엉덩이 등 총 10개의 랜드마크가 정의되었다. 이러한 정의는 의류의 구조적 특징을 설명하며, 각 랜드마크가 의류의 주요 포인트를 나타낸다. 특히, 랜드마크는 변형 과정에서 신체 랜드마크와의 상관성을 최대화할 수 있도록 설계되었다. 예를 들어, 소매의 랜드마크는 팔꿈치와 손목 랜드마크와 일관성을 유지하도록 정렬되며, 이는 자세 변화나 복잡한 의류 스타일에서도 강건한 성능을 보장한다.

의류 랜드마크 예측기는 두 가지 주요 출력을 생성한다. 첫 번째는 조인트 히트맵 M^{JH} 으로, 각 랜드마크가 특정 위치에 있을 확률을 2D 맵 형태로 나타낸다. 각 랜드마크에 대해 독립적인 히트맵이 생성되며, 이는 의류의 구조를 2차원 공간에서 명확히 표현한다. 두 번째 출력은 부분 연관 필드 M^{PAF} 로, 랜드마크 간의 구조적 연결성을 나타내는 벡터 필드이다. 이 필드는 랜드마크 간의 상대적 거리와 방향성을 학습하며, 신체 랜드마크와의 상관성을 유지하도록 설계되었다.

모델의 예측 과정은 입력 이미지 $C \in \mathbb{R}^{H \times W \times 3}$ 에서 시작하여, 네트워크를 통해 조인트 히트맵과 부분 연관 필드가 동시에 생성된다. 랜드마크의 예측은 이러한 두 출력을 결합하여 이루어지며, 랜드마크의 정확한 위치는 Hungarian 알고리즘을 활용하여 결정된다. Hungarian 알고리즘은 랜드마크 후보 지점 간의 매칭 비용을 최소화하는 방식으로 작동하며, 이는 랜드마크 위치의 최적화를 보장한다.

3.4.2. 의류 세분화 네트워크 (Clothing Segmentation Network)

의류 세분화 네트워크(Clothing Segmentation Network)는 의류를 주요 부위로 나누어 각 부위별 특성을 반영한 독립적인 처리를 가능하게 하며, 이는 가상 착용 과정에서 중요한 역할을 한다. 특히, 세분화 네트워크는 의류의 상체, 소매, 목선 주변 영역과 같은 주요 부분을 명확히 구분하여, 각 부위의 변형을 정밀하게 수행할 수 있도록 지원한다. 이러한 설계는 변형 과정에서 발생할 수 있는 왜곡을 줄이고, 결과물의 품질을 높이는 데 기여한다.

세분화 네트워크의 학습을 위해 사용된 데이터셋은 다양한 의류 스타일, 텍스처, 그리고 체형을 반영하도록 설계되었다. 각 데이터셋의 이미지는 RGB 채널을 포함하며, 각각의 픽셀은 상체, 소매, 목선 주변 영역 중 하나로 라벨링되었다. 목선 주변 영역은 “Invisible” 클래스로 정의되어 변형 과정에서 제거할 영역으로 분리되었다. 이러한 라벨링은 의류의 기하학적 구조를 명확히 표현하고, 변형 과정에서 필요한 정밀한 정보를 제공한다.

본 연구에서 제안된 세분화 네트워크는 Fully Convolutional Network (FCN)를 기반으로 설계되었다. FCN은 이미지의 픽셀 단위 세분화에 최적화된 구조로, 의류의 세부적인 부위를 효과적으로 분리할 수 있다. 입력 데이터는 RGB 이미지 $C \in R^{H \times W \times 3}$ 로 구성되며, 네트워크는 입력 데이터를 처리하여 세분화 마스크 $M_C \in R^{H \times W}$ 를 생성한다. 세분화 마스크는 각 픽셀이 특정 클래스(상체, 소매, 목선 주변 영역) 중 하나에 속하는 확률 값을 포함하며, 이러한 픽셀 단위의 확률은 최종적으로 특정 클래스에 할당된다.

네트워크는 U-Net과 같은 인코더-디코더 구조를 활용하여, 입력 이미지에서 고차원 특징을 추출하고 이를 저차원 공간에서 복원하는 과정을 통해 세분화를 수행한다. 인코더는 입력 이미지의 공간적 정보를 압축하고, 디코더는 이를 다시 복원하여 출력으로 세분화된 이미지를 생성한다. 이 과정에서 Skip Connection을 활용하여 고차원 공간에서 얻어진 세부 정보를 디코더 단계로 전달함으로써, 세분화의 정밀도를 높인다.

세분화 네트워크는 생성된 마스크를 기반으로 변형 과정에서 필요하지 않은 영역을 제거하는 역할도 수행한다. 특히, 목선 주변의 “Invisible” 클래스로 정의된 영역은 최종 변형 과정에서 제외되며, 이를 통해 신체와 의류 간의 결합이 자연스럽게 유지된다. 이러한 영역 제거 과정은 변형 중 발생할 수 있는 왜곡을 최소화하고, 결과 이미지의 품질을 개선한다.

결합 마스크는 변형 과정에서 필요한 상체와 소매 영역만을 포함하도록 생성되며, 다음과 같이 정의된다:

$$M_{elim} = M_C(torso) \cup M_C(sleeve)$$

이 과정은 목선 영역(Invisible)을 제거하여 최종 변형에 필요한 영역만을 남긴다.

3.4.3. 랜드마크 기반 변형 (Landmark-guided Transformation)

랜드마크 기반 변형(Landmark-guided Transformation)은 의류 랜드마크 K_c 와 신체 랜드마크 K_p 를 활용하여 의류를 신체에 정렬하고, 맞춤형 변형을 수행하는 과정이다. 이 과정은 Cloth Warping 기술의 핵심 단계로, 의류의 각 부위를 개별적으로 처리하며, 신체 비율에 따른 변형을 통해 사용자 맞춤형 가상 착용 결과를 생성한다. 랜드마크 기반 변형은 특히 복잡한 자세와 다양한 체형에서도 안정적인 결과를 보장하기 위해 설계되었다.

정렬 및 부위별 처리

본 연구에서 제안된 변형 과정은 상체와 팔다리를 독립적으로 처리하도록 설계되었다. 이러한 부위별 처리는 각각의 부위가 가진 변형 특성을 정밀하게 반영할 수 있도록 하며, 복잡한 자세에서도 의류와 신체 간의 자연스러운 연결을 가능하게 한다. 변형 과정은 크게 두 가지 주요 단계로 구성된다.

(1) 상체 부분의 정렬

상체 부분의 정렬은 어깨와 엉덩이를 포함하는 랜드마크 집합 K (의류 랜드마크)와 K (신체 랜드마크)를 기반으로 수행된다. 상체는 비교적 안정적인 구조를 가지며, 의류와 신체 간의 정확한 정렬이 최종 결과의 품질에 큰 영향을 미치기 때문에, 상체 변형에서는 높은 정밀도가 요구된다. 이를 위해 호모그래피 변환(Homography Transformation)을 사용하여 의류 랜드마크를 신체 랜드마크에 정렬한다. 변환 행렬 H_{torso} 는 다음과 같이 계산된다.

$$H_{torso} = \operatorname{argmin}_H \sum_i \|K_{torso,i}^P - H \cdot K_{torso,i}^C\|$$

여기서 H 는 호모그래피 행렬을 나타내며, 이는 랜드마크 간의 유클리드 거리 차이를 최소화하는 방식으로 계산된다. 계산된 H_{torso} 는 의류 상체 부분을 변형하는 데 사용되며, 변환된 결과는 C_{torsol} 로 표현된다.

(2) 팔다리 부분의 세밀한 처리

팔다리 부분은 상완(Upper Arm)과 전완(Forearm)으로 나뉘어 개별적으로 처리된다. 각 하위 팔다리 부분에 대해 랜드마크 집합 $K_{limb,i}^C$ 와 $K_{limb,i}^P$ 를 정의하며, 이를 기반으로 독립적인 호모그래피 변환을 수행한다. 이 과정은 각 팔다리 부분이 상체와 다른 움직임 특성을 가지기 때문에, 부위별로 맞춤형 변형을 가능하게 한다. 변환 행렬 $H_{limb,i}$ 는 다음과 같이 계산된다.

$$H_{limb,i} = \operatorname{argmin}_H \sum_j \|K_{limb,j}^P - H \cdot K_{limb,j}^C\|$$

여기서 $i \in \{1, 2, 3, 4\}$ 는 각 하위 팔다리 부분(좌우 상완과 전완)을 나타낸다. 계산된 변환 행

렬 $H_{limb,i}$ 를 활용하여 변환된 팔다리 부분 C_{limb} 를 생성하며, 최종적으로 상체 부분과 팔다리 부분을 결합하여 완전한 변형 결과를 얻는다.

신체 비율 기반 랜드마크 조정

본 연구는 신체의 비율에 따라 랜드마크 위치를 동적으로 조정하여, 사용자 맞춤형 변형을 가능하게 한다. 신체 비율은 상체 길이와 어깨 너비의 비율 r 로 정의되며, 다음과 같이 계산된다.

$$r = \frac{TorsoLength}{ShoulderWidth}$$

r 값은 사용자 제공 데이터 또는 신체 랜드마크 간의 거리 계산을 통해 추정된다. 이 값을 바탕으로 의류 랜드마크의 위치를 조정하여, 동일한 의류가 서로 다른 체형의 사용자에게도 자연스럽게 맞을 수 있도록 한다. 예를 들어, 상체 길이가 더 긴 사용자의 경우, 의류 랜드마크를 수직 방향으로 확장하여, 의류가 신체의 실제 비율에 맞도록 변형한다.

본 연구의 Cloth Warping 방식은 의류 랜드마크 예측, 의류 세분화 네트워크, 그리고 랜드마크 기반 변형이라는 세 가지 주요 구성 요소를 통합하여 가상 착용 과정을 완성한다. 3.5에서는 이들 세 가지 단계를 어떻게 통합하여 최종적으로 자연스러운 착용 결과를 생성하는지 논의한다. 또한, 통합 과정에서 발생할 수 있는 문제점들을 해결하기 위해 설계된 보완 메커니즘과 최적화 기술에 대해 설명한다.

3.5. Segmentation map conditioning

본 연구에서는 사람 의상 세그멘테이션 맵을 조절하여 가상 착용 시스템에서 의상의 크기 변화를 관찰하는 실험을 수행하였다. 이를 위해 세그멘테이션 맵에서 상의 부분에 해당하는 주황색으로 표시된 영역에 대해 팽창(dilation)과 침식(erosion) 연산을 적용하여 이미지 생성 과정에서 의상의 크기를 가변적으로 변경하였다.

연구에서는 가상 의류 착용에서 활용되는 VITON 데이터셋을 사용하였다. VITON 데이터셋 내 사람 의상 세그멘테이션 맵은 팔레트(Palette) 방식으로 저장되어 있다. 팔레트 방식은 이미지의 모든 픽셀을 RGB 형식의 각기 다른 색상으로 저장하는 것이 아닌, 이미지 내에서 사용되는 색상 목록을 팔레트 색상 테이블에 저장하고, 각 픽셀은 이 팔레트의 색상 인덱스를 참조하여 색을 표현하는 방식을 사용한다. 사람 의상 세그멘테이션 맵에서는 상의를 나타내는 색상이 주황색(인덱스: 5)이며, 이를 기반으로 이진 마스크를 생성하였다. 이 마스크에서는 주황색 상의 영역이 1로, 나머지 영역을 0으로 설정하여 상의 부분만을 선택적으로 조작할 수 있게 하였다.

주황색 영역의 크기를 가변적으로 변경하기 위해 OpenCV 라이브러리를 이용하여 이진 마스크 이미지에 팽창과 침식 연산을 수행하였다. 팽창과 침식 연산에서는 (30, 30) 크기의 정사각형 커널을 사용했고, 1번만 반복하여 확장되는 크기를 제어하였다. 팽창 및 침식 연산을 적용한 이진 마스크를 바탕으로, 원본 세그멘테이션 맵의 주황색 영역을 조절된 영역으로 대체하기 위해 새로운 세그멘테이션 맵을 생성하였다. 구체적으로, 원본 주황색 영역을 0으로 초기화한 뒤, 팽창 또는 침식이 적용된 마스크의 주황색 영역을 새로운 주황색 인덱스로 설정하여 결합된 이미지를 만들었다. 이렇게 생성된 세그멘테이션 맵을 모델 추론 과정에 입력하여, 의상의 크기 변화가 실제 가상 착용 결과에 어떻게 미치는지 관찰하였다. 이 방법을 통해, 모델이 입력으로 받는 세그멘테이션 맵의 크기 조절에 따라 출력 이미지에서 의상의 크기가 변화하는지에 대한 실험적 검증을 수행하였다. 이를 통해 가상 착용 시스템에서의 의상 조절 가능성을 탐색하였다.

3.6. 실험 환경 및 데이터셋

본 연구에서는 실험에 RTX A6000 GPU를 사용하였으며, 데이터셋으로는 VITON-HD를 활용하였다. VITON-HD는 고해상도 가상 착의(virtual try-on) 연구를 위해 설계된 데이터셋으로, 총 13,679쌍의 이미지로 구성되어 있다. 각 데이터는 1024×768 해상도의 정면 여성 모델 이미지와 상의 의류 이미지 쌍으로 이루어져 있으며, 페어드(paired) 설정으로 모델이 착용한 의류를 기반으로 생성 작업을 수행할 수 있다.

VITON-HD 데이터셋은 훈련 데이터 11,647쌍과 테스트 데이터 2,032쌍으로 분리되어 있으며, 팔레트 기반 데이터가 의류와 모델의 세그멘테이션 정보를 제공한다. 본 연구에서는 이러한 팔레트 데이터를 입력 데이터로 활용하여 모델의 세분화된 정보 학습을 가능하게 하였다. 본 연구의 가상 착의 파이프라인은 총 300k 반복 학습을 진행하였으며, 배치 크기는 16으로 설정하였다.




Figure 2. Model Architecture

4. 연구결과

평가 지표

본 연구에서는 가상 착용 모델의 성능을 정량적으로 평가하기 위해 다양한 평가 지표를 사용하였다. 이를 통해 생성된 이미지의 품질, 구조적 유사성, 그리고 현실성을 종합적으로 측정하고자 하였다. 생성된 이미지의 모델이 의상과 신체 간의 매칭을 얼마나 잘 수행했는지 평가하기 위해 LPIPS(Zhang et al., 2018), SSIM(Wang et al., 2004)를 사용했으며, 생성된 이미지의 모델이 현실적인 이미지를 얼마나 잘 생성했는지 평가하기 위해 FID(Heusel et al., 2017)을 사용했다.

1. LPIPS (Learned Perceptual Image Patch Similarity)

LPIPS는 생성된 이미지와 실제 레퍼런스 이미지 간의 지각적 유사성을 측정하기 위해 사용된다. 수학적 정의는 다음과 같다:

$$LPIPS(I_1, I_2) = \sum_l \frac{1}{H_l W_l} \sum_{h,w} \| \phi_l(I_1)_{h,w} - \phi_l(I_2)_{h,w} \|_2^2$$

I_1, I_2 는 비교할 두 이미지이고, ϕ_l 은 U-Net 모델의 l 번째 레이어에서 추출된 특성 맵이고, H_l, W_l 은 특성 맵 ϕ_l 의 높이와 너비이다. LPIPS는 특성 맵의 각 위치에서 L2 거리를 계산하며, 값이 낮을수록 두 이미지가 지각적 차이가 적음을 의미한다. LPIPS는 가상 착용에서 텍스처 디테일과 전반적인 품질 차이를 평가하기 위해 사용된다.

2. SSIM (Structural Similarity Index Measure)

SSIM은 두 이미지 간의 구조적 유사성을 평가하기 위해 설계된 지표로, 밝기, 대비, 구조의 세 가지 요소를 통합적으로 비교한다. 수학적 정의는 다음과 같다:

$$SSIM(I_1, I_2) = \frac{(2\mu_1\mu_2 + C_1)(2\sigma_{12} + C_2)}{(\mu_1^2 + \mu_2^2 + C_1)(\sigma_1^2 + \sigma_2^2 + C_2)}$$

μ_1, μ_2 는 I_1, I_2 의 평균 밝기, σ_1^2, σ_2^2 는 I_1, I_2 의 분산, σ_{12} 는 I_1, I_2 간의 공분산, C_1, C_2 는 안정성을 위해 추가된 작은 상수이다. SSIM 값은 -1에서 1 사이의 값을 가지며, 1에 가까울수록 두 이미지가 구조적으로 유사함을 나타낸다. SSIM은 가상 착용에서 의상과 신체의 윤곽, 포즈 매칭의 정확성을 측정하기 위해 사용된다.

3. FID (Frechet Inception Distance)

FID는 생성된 이미지와 실제 데이터 분포 간의 차이를 측정하는 지표로, 이미지의 평균과 공분산을 계산하여 다변량 가우시안(Multivariate Gaussian)으로 만든 뒤, Frechet distance를 사용하여 두 분포 사이의 거리를 측정한다. 수학적 정의는 다음과 같다:

$$FID = \left\| \mu_r - \mu_g \right\|_2^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{\frac{1}{2}})$$

μ_r, μ_g 는 각각 실제 데이터와 생성된 데이터의 평균 특성 벡터이고, Σ_r, Σ_g 는 각각 실제 데이터와 생성된 데이터의 공분산 행렬이고, Tr 은 행렬의 대각 합이다. FID가 낮을수록 생성된 데이터가 실제 데이터와 유사한 분포를 가지고 있음을 나타낸다.

측정 결과

모델	LPIPS ↓	SSIM ↑	FID(paired) ↓	FID(unpaired) ↓
CP-VTON	-	0.791	-	30.35
ACGPN	-	0.858	-	14.43
VITON-HD	0.116	0.863	11.01	12.96
HR-VTON	0.097	0.878	10.88	13.06
LaDi-VTON	0.091	0.876	6.66	9.41
OURS	0.129	0.867	10.86	15.11

Figure 3. VITON-HD 데이터에 대한 대표적인 모델의 측정 결과

Test Result Image



Figure 4. 다양한 warping 비율에 따른 변화

각 열에서 $R=0.6$, $R=0.8$, $R=1.0$, $R=1.2$, $R=1.4$ 는 warping 비율을 의미하며, 워핑 비율 (warping ratio)에 따른 생성 이미지의 변화가 비율적으로 일관된 경향을 보였다. 비율 값이 0.6, 0.8, 1.0 순으로 증가함에 따라 소매 길이가 점진적으로 변화하였다.



Figure 5. 워핑 비율($R=0.6$, $R=0.8$)에서 세그멘테이션 맵 추가 여부에 따른 질적 결과 비교

Segmentation map을 추가로 제공했을 때, warping 비율이 0.6과 0.8인 경우 의상의 크기를 효과적으로 확대할 수 있음을 확인할 수 있었다. 이는 segmentation map이 warping 과정에 영향을 미쳐 의상의 크기 조정을 보다 정확하게 수행하도록 돕는 역할을 한다는 점을 보여준다.



Figure 6. 다양한 워핑 비율에서 세그멘테이션 맵 추가 여부에 따른 질적 결과 비교

또한, 우리 모델의 입력 레이어에 Segmentation map을 추가로 제공함으로써 의상의 경계를 보다 명확하게 구분할 수 있었으며, 신체 일부가 잘리는 등의 오류를 효과적으로 감소시킬 수 있었다. 이러한 개선은 세그멘테이션 맵을 통합했을 때 의상이 더 정확하게 정렬되고, 가상 피팅결과에서 신체의 형태가 보존되는 모습을 통해 확인할 수 있다.

Erosion 30

Erosion60

Dilation 30

Dilation 60




Figure 7. 세그멘테이션 맵의 의류 커널 크기에 따른 실험 결과(침식으로 인한 부피 감소와 팽창으로 인한 부피 증가)

커널 크기를 30과 60으로 나누어 비교한 결과, 세그멘테이션 맵의 변형이 가상 시착 모델에서 의류의 부피와 착용감을 정확하게 표현하는 데 중요한 영향을 미친다는 것을 확인할 수 있었다. 특히, 세그멘테이션 맵의 크기를 축소하거나 확장함으로써 의류의 부피와 실루엣이 변화하며, 이러한 변화는 최종적으로 생성된 이미지에서 의류의 착용감과 적합도에 눈에 띄는 차이를 만들어낸다.




Figure 8. 다양한 warping 비율에 따른 변화

Erosion 30

Erosion 60

Dilation 30

Dilation 60




Figure 9. 세그멘테이션 맵의 의류 커널 크기에 따른 실험 결과 (Erosion(30, 60)으로 인한 부피 감소와 Dilation(30, 60)으로 인한 부피 증가)

5. 논의

우리 모델의 추론 결과를 기존 VTON 모델들과 비교한 결과 FID, LPIPS, SSIM 등의 평가 지표에서 기존 모델 대비 낮은 점수를 기록하였다. 그러나 일부 이미지에서는 기존 모델보다 우수한 결과를 보이는 경우도 관찰되었는데, 이는 워핑 모듈(warping module)을 통해 생성된 워핑된 의류 이미지가 원본 인물 이미지를 벗어났을 경우, 기존 모델에서는 신체와 의류 경계가 침범되는 현상이 발생한 반면, 우리 모델은 입력 계층에 제공된 세그멘테이션 맵이 가이드라인 역할을 하여 이미지 경계를 유지하며 생성 정밀도를 향상시켰기 때문으로 해석된다.

사이즈 조정을 목적으로 세그멘테이션 맵의 의류 커널(kernel) 크기를 조정한 데이터를 입력으로 사용한 추론 결과, 세그멘테이션 맵의 변형이 실제 이미지 생성에 유의미한 영향을 미친다는 점을 확인할 수 있었다. 전반적으로 커널 크기 조정에서 팽창(dilation)이 침식(erosion)보다 더 효과적인 사이즈 조절 결과를 나타냈다. 커널 크기를 30과 60으로 나누어 비교했을 때, 생성 이미지의 사실성은 커널 크기가 30인 경우 더 높았다. 커널 크기에 따른 결과가 항상 비례하지는 않았으며, 일부 이미지에서는 거의 변형이 없거나 왜곡된 결과가 발생하였다. 이는 세그멘테이션 맵이 생성 이미지에 가이드라인 역할을 하며 정성적인 영향을 주는 것을 의미한다.

사이즈 조정을 위해 사이즈 조절을 위한 워핑 모듈로 생성된 의류 이미지로 추론을 진행한 결과, 워핑 비율(warping ratio)에 따른 생성 이미지의 변화가 사이즈에 따라 일관된 경향을 보였다. 즉, 비율 값이 1.0, 0.8, 0.6 순으로 감소함에 따라 소매 길이가 점진적으로 늘어났다. 그러나 침식된 워핑 의류 이미지를 사용한 추론에서는 팽창 대비 사이즈 조절 효과가 미미했다. 침식의 경우, 정상적으로 생성된 이미지에서는 비율 값에 따라 옷의 사이즈가 늘어났지만, 사이즈 조절에 실패하거나 또는 왜곡된 이미지가 발생하는 빈도가 상대적으로 높았다.

마지막으로, 세그멘테이션 맵 조정(커널 크기 30)과 워핑된 의류 이미지를 동시에 적용하여 추론을 진행한 결과, 세그멘테이션 맵과 워핑된 의류 이미지의 조합이 더 자연스러운 사이즈 조정 결과를 가져왔다. 세그멘테이션 맵은 옷의 핏, 길이 등의 정성적 변화를 유도하며 이미지 생성에서 보조적인 가이드 역할을 수행하였음을 확인할 수 있었다. 이 또한 상대적으로 팽창에서 침식보다 유의미한 효과를 보였다.

6. 결론 및 발전방향

결론적으로, 본 연구에서는 추가적인 학습 데이터를 필요로 하지 않으면서도 효과적으로 사이즈 조절 기능을 수행할 수 있는 VTON 모델을 구현했다. 기존의 대부분 VTON 모델들은 의류 착용 이미지 생성에 초점을 맞추고 있으며, 최근 Diffusion을 활용한 연구들은 주로 의류 이미지와 사람 이미지만을 사용하여 이미지를 생성하는 방식에 의존하고 있다. 이러한 기존 방식은 자연스러운 이미지를 생성하는 데에는 성공적이지만, 사이즈 조절과 같은 특수한 작업에는 한계가 있었다.

본 연구는 이러한 한계를 극복하기 위해 완전히 새로운 접근을 제시했다. 사이즈 조절을 위한 추가적인 학습 데이터 없이도, 우리는 워핑 모듈과 입력 데이터 전처리를 통해 사이즈 조절 기능을 구현하였다. 구체적으로, 본 연구에서는 워핑 의류, 원본 마스킹 이미지, 포즈 맵, 그리고 세그멘테이션 맵을 입력 데이터로 활용하였다. 세그멘테이션 맵은 이미지 생성 과정에서 가이드라인 역할을 하여 입력 데이터 변형에 대한 강건성을 제공했고, 이는 사이즈 변형에서도 높은 성능을 유지할 수 있게 했다. 특히, 워핑 모듈을 사용해 옷의 크기를 비율에 맞게 확장하거나 축소함으로써, 세그멘테이션 맵과의 조화를 통해 매우 자연스럽게 현실감 있는 사이즈 조절을 가능하게 했다.

기존의 연구 방식과 달리, 본 연구의 접근은 사이즈 조절을 목적으로 한 새로운 방법론을 제시했다는 점에서 큰 의의를 가진다. 추가적인 데이터 없이도 강력한 사이즈 조절 성능을 달성한 본 모델은 향후 VTON 기술의 발전에 중요한 기여를 할 것으로 기대된다. 또한, 입력 데이터의 정교한 전처리와 워핑 모듈의 활용을 통해, 다양한 신체 유형과 특수한 요구에 맞춘 개인화된 착용 이미지를 생성하는 데에 있어서도 높은 잠재 가치를 지닌다. 본 연구의 결과는 VTON 모델이 더욱 현실적이고 유연하게 발전할 수 있는 가능성을 열어주었으며, 이는 향후 연구와 상용화에 있어 중요한 밑거름이 될 것이다.

발전 방향

생성 이미지 구조와 입력 이미지의 관계를 시각적으로 분석한 결과, 이미지 생성 과정에서 워핑 모듈에 의해 생성된 워핑된 의류 이미지의 구조가 큰 영향을 미치는 것으로 확인되었다. 반면, 세그멘테이션 맵의 변화는 워핑 의류에 비해 상대적으로 미미한 영향을 끼쳤다. 이는 세그멘테이션 맵의 인덱스 값이 0에서 17 사이로 제한된 반면, 다른 입력 요소와의 스케일 차이가 커 극적인 변화를 확인하기 어려웠기 때문으로 보인다. 이러한 스케일 차이는 세그멘테이션 맵 값을 정규화(normalization)하여 해결할 수 있을 것으로 판단된다.

사이즈 조절 실험에서는 팽창 기법이 효과적인 결과를 보였으나, 침식 과정에서는 공백 처리의 한계로 인해 하얀 배경이 드러나 성능 저하가 관찰되었다. 침식으로 인해 발생한 공백을 효과적으로 처리하기 위해 원본 세그멘테이션 맵과 변형된 세그멘테이션 맵을 병합하여 활용하거나, 후처리 기법으로 공백을 재생성하는 방안을 고려할 수 있다. 또한, 워핑된 의류 이미지와 세그멘테이션 맵 커널 조정을 병행하면 두 변형 이미지 간의 형태 일관성을 높여 성능 향상에 기여할 가능성이 있다. 이를 위해 워핑된 의류 이미지에 적합한 세그멘테이션

맵을 생성하는 별도의 모듈을 추가하거나, 세그멘테이션 맵의 특징을 추출하여 입력 데이터로 활용하는 방안을 제안한다.

향후 연구에서는 단순히 시각적 일관성을 넘어, 실제 의류 착용 시의 물리적 적합성까지 모델이 고려할 수 있는 방향으로 확장할 필요가 있다. 이를 위해 기하학적 변형과 소재 특성을 동시에 반영한 새로운 데이터 생성 기법이나, 기존 워핑 모듈의 성능을 더욱 정교화할 수 있는 알고리즘 개발이 유의미할 것이다. 이러한 접근은 개인화된 가상 착용 시스템 구축에도 기여할 수 있을 것으로 기대된다.

Reference

- Song, D., Zhang, X., Zhou, J., Nie, W., Tong, R., Kankanhalli, M., & Liu, A.-A. (2024). Image-Based Virtual Try-On: A Survey. arXiv. <https://arxiv.org/abs/2303.12345>
- Tang, M., Wang, H., Tang, L., et al. (2016). CAMA: Contact-aware matrix assembly with unified collision handling for GPU-based cloth simulation. *Computer Graphics Forum*, 35(2), 511-521. <https://doi.org/10.1111/cgf.12851>
- Tang, M., Liu, Z., Tong, R., et al. (2018a). PSCC: Parallel self-collision culling with spatial hashing on GPUs. *Proceedings of the ACM on Computer Graphics and Interactive Techniques*, 1(1), 18:1-18:18. <https://doi.org/10.1145/3203188>
- Tang, M., Wang, T., Liu, Z., et al. (2018b). I-cloth: Incremental collision handling for GPU-based interactive cloth simulation. *ACM Transactions on Graphics*, 37(6), 204. <https://doi.org/10.1145/3272127.3275005>
- Ge, Y., Liu, Z., Wang, F., et al. (2021). PFAFN: Progressive feature alignment and fusion network for precise virtual try-on. arXiv preprint arXiv:2103.04559. <https://arxiv.org/abs/2103.04559>
- Zhu, J.-Y., Park, T., Isola, P., & Efros, A. A. (2017). Unpaired image-to-image translation using cycle-consistent adversarial networks. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. <https://doi.org/10.48550/arXiv.1709.0469>
- Ge, Y., Song, Y., Zhang, R., Ge, C., Liu, W., & Luo, P. (2021). Disentangled cycle-consistent tensor alignment for virtual try-on. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.48550/arXiv.2103.09479>
- Ge, Y., Zhang, R., Song, Y., Ge, C., Liu, W., & Luo, P. (2021). Parser-free virtual try-on via distilling appearance flows. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.48550/arXiv.2103.0455>
- Jiang, T., Sun, S., Tang, C., & Fu, H. (2022). SF-VTON: Learning geometric transformation for self-fashion virtual try-on. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.48550/arXiv.2204.01046>

Wang, B., Zheng, H., Liang, X., Chen, Y., Lin, L., & Yang, M. (2018). Toward characteristic-preserving image-based virtual try-on network. arXiv preprint arXiv:1807.07688. <https://doi.org/10.48550/arXiv.1807.07688>

Yang, H., Zhang, R., Wang, X., Luo, J., & Tang, X. (2020). Towards photo-realistic virtual try-on by adapting segmentations with semantic correlation. arXiv preprint arXiv:2003.05863. <https://doi.org/10.48550/arXiv.2003.05863>

Morelli, A., Barbano, V., & Galteri, L. (2023). Latent diffusion models for virtual try-on. arXiv preprint arXiv:2305.13501. <https://doi.org/10.48550/arXiv.2305.13501>

Han, X., Wu, Z., Wu, Z., Yu, R., & Davis, L. S. (2018). VITON: An Image-Based Virtual Try-On Network. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 7543–7552. <https://doi.org/10.48550/arXiv.1711.08447>

Gou, J., Sun, S., Zhang, J., Si, J., Qian, C., & Zhang, L. (2023). Taming the power of diffusion models for high-quality virtual try-on with appearance flow. Proceedings of the 31st ACM International Conference on Multimedia (ACM MM 2023). <https://doi.org/10.1145/3581783.3612255>

Ge, Y., Song, Y., Zhang, R., Ge, C., Liu, W., & Luo, P. (2021). Parser-free virtual try-on via distilling appearance flows. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2021), 8485–8493. <https://doi.org/10.1109/CVPR46437.2021.00837>

Han, X., Wu, Z., Wu, Z., Yu, R., & Davis, L. S. (2019). ClothFlow: A flow-based model for clothed person generation. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV 2019), 10471–10480. <https://doi.org/10.1109/ICCV.2019.01077>

Lee, S., Gu, G., Park, S., Choi, S., & Choo, J. (2022). High-resolution virtual try-on with misalignment and occlusion-handled conditions. Proceedings of the European Conference on Computer Vision (ECCV 2022). https://doi.org/10.1007/978-3-031-20059-6_2

Xie, Z., Huang, Z., Zhao, F., Dong, H., Kampffmeyer, M., & Liang, X. (2021). Towards scalable unpaired virtual try-on via patch-routed spatially-adaptive GAN. Advances in Neural Information Processing Systems (NeurIPS 2021), 34, 2949–2961.

<https://doi.org/10.48550/arXiv.2111.10544>

Cui, A., He, S., Xiang, T., & Toisoul, A. (2023). Learning garment DensePose for robust warping in virtual try-on. arXiv preprint. <https://doi.org/10.48550/arXiv.2303.17688>

Chen, C.-Y., Chen, Y.-C., Shuai, H.-H., & Cheng, W.-H. (2023). Size does matter: Size-aware virtual try-on via clothing-oriented transformation try-on network. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 7513–7522.